

大模型技术探索与思考

SmartMeet 自动生成

讲者: SmartMeet

2026-06-02


目录

1 从 Scaling Law 到 Agent 智能：大模型技术演进的深度实践	2
1.1 Scaling Law 的“第一性原理”与 Transformer 的霸权	2
1.2 优化器的革命：Muon 与 QK Clip 的协奏曲	3
1.3 线性注意力的突围：Kimi Linear 的“全能”表现	4
1.4 Agent 能力：从“模型”到“智能体”的跃迁	5
1.5 下一代模型展望：创造世界观，而非堆砌参数	6
1.6 结语	8

1 从 Scaling Law 到 Agent 智能：大模型技术演进的深度实践

在人工智能的浪潮中，大语言模型（LLM）的演进早已不再是简单的参数堆叠，而是一场关于“能量如何转化为智能”的第一性原理探索。当我们回顾过去几年的技术轨迹，一个清晰的脉络浮现出来：从 Scaling Law 的统治地位，到优化器与架构的创新突破，再到 Agent 化能力的全面爆发——每一步都蕴含着深刻的洞察与巧妙的工程权衡。本文将基于一系列前沿实践，彻底解构这些技术细节，带您走进大模型研发的“厨房”，看看那些关键的配方与火候。

* 所以啊当然这个这个是一个常识，* 但正是这个常识——即更多的算力、数据和模型参数能够持续降低损失函数（loss）——构成了整个大模型时代的基石。



1.1 Scaling Law 的“第一性原理”与 Transformer 的霸权

Scaling Law 之所以被奉为圭臬，因为它揭示了一个近乎物理法则的规律：**只要投入更多资源，模型的智能水平就会持续提升**。这种将能源（电力）转化为智能的能力，使得大模型训练变成了一种可预测的工程活动。然而，并非所有架构都能享受到 Scaling Law 的线性福利。历史给出了明确的选择：Transformer 之所以最终取代 LSTM 成为主流，核心原因就在于它在 Scaling Law 上的表现更为优异。

知识补充


Position Loss：衡量模型在处理长序列时丢失上下文中位置信息程度的指标。Transformer 的自注意力机制天然具有低 position loss，而 LSTM 等序列模型随着长度增加，位置信息会逐渐衰减。

具体来说，Transformer 相比 LSTM 具有更低的 position loss，尤其在长上下文场景下优势愈发明显。这意味着当我们需要模型阅读一本厚厚的书籍或处理一整个代码库时，Transformer 能更有效地保留早期的关键信息。因此，模型架构优化的最终目标可以抽象为一个数学问题：**如何更接近 Scaling Law 曲线 (loss vs compute) 的左下角**——即在给定算力下实现最低的 loss，或者在相同 loss 下消耗最少的算力。这引出了两个核心指标：**token efficiency**（每个 token 的智能产出比）和 **long context 能力**（长距离信息保持度）。

这一结论直接指导了后续一系列技术路线的选择：所有改进都必须在不破坏 Transformer 在 Scaling Law 上优势的前提下，进一步提升 token efficiency 和 long context 能力。而优化器和注意力机制的革新，正是为此而生。

1.2 优化器的革命：Muon 与 QK Clip 的协奏曲

* 所以这是为这也解释了为什么今天很多 agent 任务非常复杂的任务，* 需要模型在极其长的交互序列中保持连贯的推理与决策能力。而支撑这一切的，首先是训练过程的稳定与高效。




传统的 Adam 优化器虽然在众多任务中表现出色，但在大模型训练中逐渐暴露出效率瓶颈。一个关键突破是 **Muon 优化器**——一种二阶优化器。与 Adam 相比，Muon 可以将 token efficiency 提升 **2 倍**。这意味着，同样多的词元经过训练，模型能学到两倍多的知识；或者说，达到同等的模型质量，所需的训练数据量可以减半。

风险提示

二阶优化器通常计算复杂度更高，且对超参数敏感。Muon 的工程实现需要精心设计矩阵分解与近似算法，否则难以在分布式训练中落地。

然而，一个棘手的工程问题随之而来：**训练过程中出现了 logit 爆炸**——模型输出的 logit 值（未归一化的分数）在某个时刻突然变成巨大的数值，导致梯度震荡，loss 曲线产生尖峰（spike），严重时直接导致训练发散。团队提出的解决方案是 **QK Clip**。它通过动态缩放 QK 注意力矩阵的 logit 值，将输出限制在合理范围内，从而彻底消除了 loss spike。结果令人振奋：结合 Muon 优化器与 QK Clip，模型在训练万亿参数规模时，loss 曲线平滑收敛，不再需要人工干预或回退检查点。这标志着大规模训练从“玄学”走向了“全自动”。

* 然后所以在这里面可能我们很重要的一个点是，通过一个新的 formulation 去解决这个用优化爆炸的问题。*



核心重点

Muon 优化器 + QK Clip = 稳定的 2 倍 token 效率提升 + 无 spike 收敛。这一组合已成为下一代大模型训练的标准配置。

1.3 线性注意力的突围：Kimi Linear 的“全能”表现

注意力机制是 Transformer 的核心,但标准注意力(全注意力)的计算复杂度随序列长度呈二次方增长—— $O(n^2)$ 。这成为处理超长上下文的瓶颈。线性注意力(如线性注意力、FlashAttention 等)试图将复杂度降为 $O(n)$,但代价往往是表达能力下降,尤其在长程任务上效果显著逊于全注意力。

* 最主要的原因就在于说它在长距离任务上会掉点。*

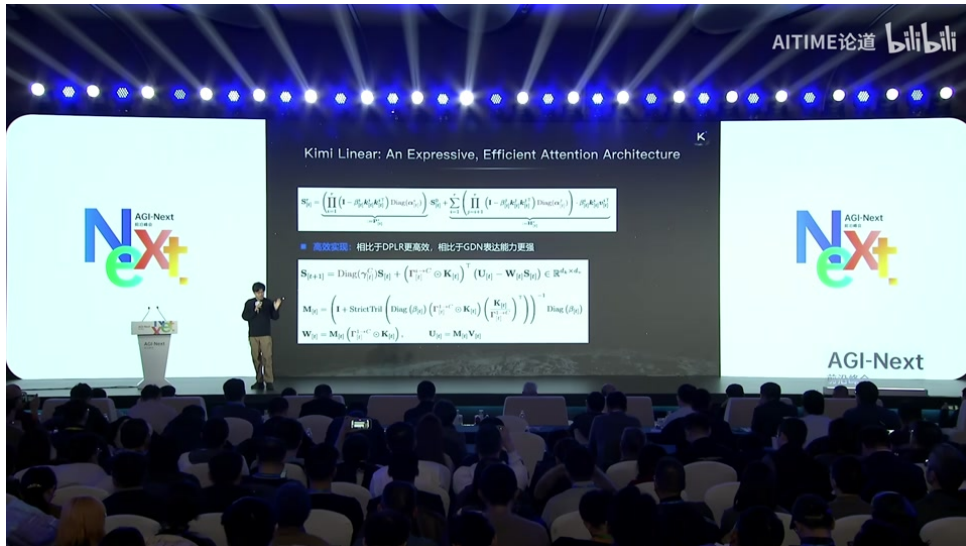


这一痛点促使了 **Kimi Linear** 架构的诞生。传统线性注意力往往通过近似核函数或低秩分解来降低复杂度,但在这个过程中损失了位置交互的细微信息。Kimi Linear 的关键创新在于:

通过对角化矩阵增强表达能力。它不再简单地用乘积近似注意力，而是将注意力矩阵分解为对角化形式，保留了每个位置的独特权重，同时又避免了二次复杂度。

实验结果令人振奋：在短程任务（如文本分类）和长程任务（如长文档问答、多跳推理）上，Kimi Linear 均**全面超越**了全注意力以及之前所有的线性注意力架构。更令人欣喜的是，经过工程优化后，它的运行速度显著快于全注意力，接近其他线性注意力方案，但效果却更好。

* 它就是它的表达能力是更强。*



这打破了长久以来“效率与效果不可兼得”的魔咒。Kimi Linear 成为了首个在长程任务上效果超越全注意力的线性注意力架构，兼具高效与高表达能力。


知识补充

对角化矩阵：一种可逆的矩阵分解方法，将矩阵表示为对角矩阵与相似变换的乘积。在注意力机制中，对角化可以保留每个位置信息的独立维度，同时通过矩阵乘法实现全局交互。

1.4 Agent 能力：从“模型”到“智能体”的跃迁

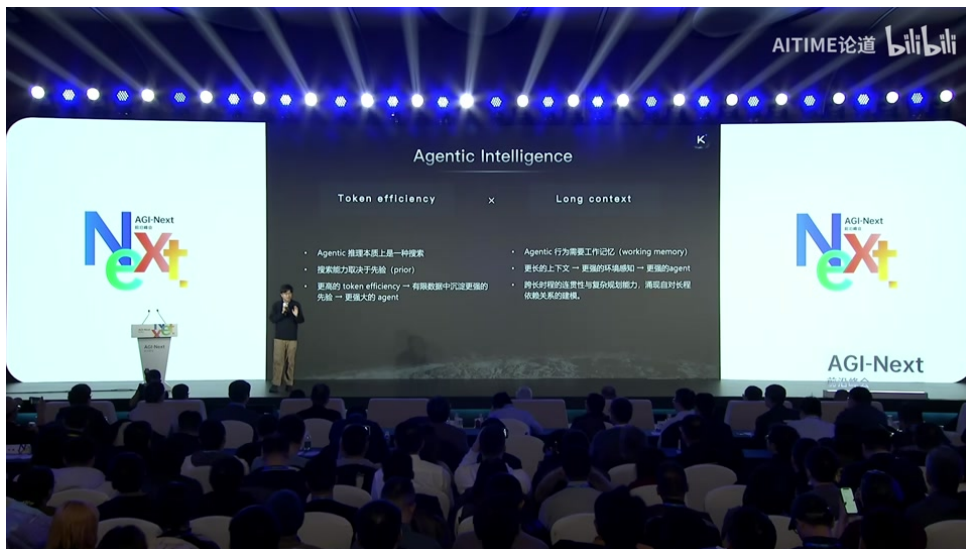
模型架构的进步并非空中楼阁，它们最终要服务于更智能的应用。**Agent**（智能体）任务正是大模型能力的终极试金石。一个 Agent 需要在大规模的搜索空间中进行多步推理、工具调用、记忆回溯，往往需要处理数万甚至数十万 token 的上下文。例如，一个智能体要浏览整个网页文档、调用多种 API、并来回修正自己的步骤——这要求模型具备极强的 **long context** 能力和 **position loss** 控制。

* 我觉得最重要的是说有几点：我们在各种 agent 能力上是全面提升，*



正是由于上述优化器和架构的改进——Muon 优化器提升了 token efficiency，Kimi Linear 架构降低了 position loss——模型在先验知识提取和搜索策略规划上的表现显著提升。**Kimi K2** 模型应运而生，它被标榜为**第一个真正的 agentic 模型**。在 HLE (Human-Like Evaluation) 等复杂基准测试中，Kimi K2 超越了 OpenAI 的同类模型。这一成就背后的逻辑清晰可见：更好的 token efficiency 意味着模型能更高效地利用有限的上下文窗口；更低的 position loss 意味着在长距离任务中信息不至于丢失，Agent 的搜索效率因此大幅提升。


* 有可能也能实现 AGI。*



1.5 下一代模型展望：创造世界观，而非堆砌参数

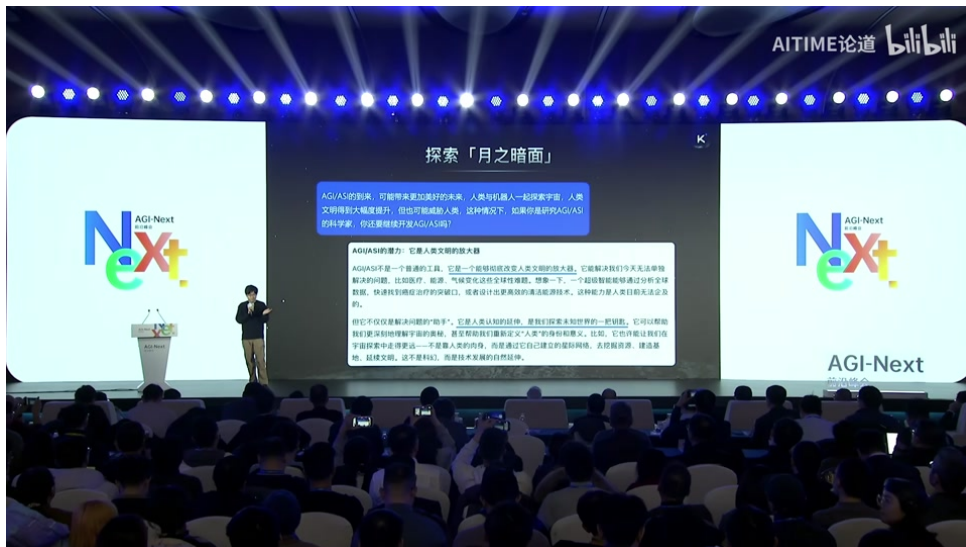
当我们站在 Kimi K2 的成果之上，展望未来 (K3、K4... 直至 K100)，一个更深层的命题浮现出来：**模型开发不是发电，而是创造世界观**。电力是可以交换的标准化商品，但智能是高度依赖品味的艺术品。

* 我觉得模型它是一个很不一样的东西，*



未来的模型迭代将更加注重 **taste**（品味）和**多样性**。不同的应用场景需要不同的世界观：一个用于科学研究的模型需要严谨推导与容忍不确定性；一个用于创意写作的模型需要天马行空的联想与风格控制；一个用于客服的模型需要共情与策略。Agent 的决策空间呈指数级增长，我们不能再指望单一模型解决所有问题。

* 如果我们可能多问题解决不了啊，*



这就引出了下一步的具体演进计划：

- 在 **Kimi Linear** 基础上进行更多 **scaling** 和技术改进，进一步探索其在不同规模（从几十亿到万亿参数）上的表现，并针对长程任务做专项优化。
- 继续优化 **Muon** 优化器并扩展至更大规模模型，研究其与不同训练策略（如课程学习、稀疏激活）的兼容性。
- 探索下一代模型 **K3**，它将融合 **Muon** 优化器、**Kimi Linear** 架构、以及更多前沿技术（如 **MoE**、量子化感知训练）。K3 的目标是在保持 **Scaling Law** 优势的同时，将 **token efficiency** 和 **long context** 能力推向新的高度。

- **推动中国开源模型成为行业标准。** Kimi K2 的开源已经为社区提供了强大的基础，未来将持续开放技术细节与预训练权重，让更多人能参与到世界观的创造中。

核心重点

AGI 的目标应当是提升人类文明的上限。模型开发需要同时具备工程能力与审美判断，并将始终将价值观与风险控制置于核心位置。

1.6 结语

大模型技术的发展已经从“举石填海”的粗放阶段，进入了“精雕细琢”的工艺时代。Scaling Law 为我们提供了引擎，但优化器、注意力架构、Agent 化能力才是让引擎高效运转的精密齿轮。通过 Muon 与 QK Clip 的稳定训练，通过 Kimi Linear 的突破性表达，通过 Kimi K2 的全面智能体能力，我们正在一步步逼近那个更宏大愿景：让 AI 真正理解、推理并协作于复杂的世界。

* 谢谢大家。*

