

大模型训练优化与架构创新技术分享

SmartMeet 自动生成

讲者: SmartMeet

2026-06-08

目录


1	从 Scaling Law 到 Kimi Linear: 大模型训练优化与架构创新的演进之路	2
1.1	1. 基石: Scaling Law 与 Transformer 的不可替代性	2
1.2	2. 预训练的两大杠杆: Token 效率与上下文长度	3
1.2.1	2.1 Token Efficiency: 用更少的信息结晶更好效果	3
1.2.2	2.2 Long Context: 拓宽模型的信息带宽	4
1.3	3. Muon 优化器与 QK Clip: 稳定训练的秘密武器	4
1.4	4. Kimi Linear 架构与 Delta Attention: 下一代基础模型的雏形	6
1.5	5. 超越基准: Agent 能力与模型审美	7
1.6	6. 下一步演进与计划: 从 K2 到 K3 的路线图	8
1.6.1	近期关键任务	8

1 从 Scaling Law 到 Kimi Linear：大模型训练优化与架构创新的演进之路

人工智能的终极愿景——通用人工智能（AGI）——正从科幻走向工程实践。每一次模型参数的指数级增长、每一轮训练框架的颠覆性创新，都在将“能源转化为智能”这一朴素逻辑推向新的边界。我们今天所讨论的，并非孤立的算法改良，而是一整套环环相扣的技术链条：从 Scaling Law 的必然性，到 Transformer 架构的统治力，再到预训练策略的精细化设计，直至新一代线性注意力架构与智能体的深度融合。这不仅是一次技术汇报，更是一场关于下一代大模型如何炼成的方法论沉思。


1.1 1. 基石：Scaling Law 与 Transformer 的不可替代性

大模型的底层逻辑早已被 Scaling Law 所刻画：投入更多的算力、数据和参数，模型的 loss 会以可预测的方式线性下降。这听起来像是一种“暴力美学”，但其中真正的关键节点在于——什么样的架构能最有效地承接这种规模扩展？



知识补充

Position loss 是衡量模型在不同上下文长度下性能衰减程度的指标。模型在短序列上训练良好，不保证在长序列上同样优秀。Transformer 由于全连接注意力，理论上每个位置都能直接关注所有历史位置，因此 Position loss 下降更平稳。



核心重点


结论：Transformer 凭借其在长上下文下的优异表现成为主流架构。未来的模型迭代不当盲目追求参数规模的增加，而应当以 loss 曲线的下降为硬指标，确保每一层参数都在为降低不确定性做贡献。

1.2 2. 预训练的两大杠杆：Token 效率与上下文长度

然而，仅仅依赖 Scaling Law 扩展参数是不够的——算力、数据和时间都不可能无限供给。于是，预训练阶段出现了两个明确的优化方向，它们如同杠杆的两端，共同撬动智能上限。


1.2.1 2.1 Token Efficiency：用更少的信息结晶更好效果

第一个方向是 **Token efficiency**——让模型在消耗相同数量 token 的情况下，学到更高质量的表征。这本质上是数据效率的革命：不是所有 token 生而平等，高质量的代码、逻辑清晰的文本、经过筛选的语料，其信息密度远高于冗余的日常对话。通过精心设计的数据配比、课程学习（curriculum learning）以及知识蒸馏技术，我们可以用更少的预训练 token 达到接近原本全量数据的效果。



1.2.2 2.2 Long Context: 拓宽模型的信息带宽

第二个方向是 **Long context**——延长模型能处理的上下文长度，使其能够一次性读取整本书、整个代码库或累计数百轮对话历史。长上下文能力直接降低 Position loss，并显著增强 Agent 任务的表现。当模型能记住更久远的信息时，它才能做出更连贯、更合理的决策。




核心重点

结论：预训练策略应当同时推进 token efficiency 和 long context 两个方向。二者结合，才能让模型在 Agent 任务中实现真正的“记忆”与“推理”协同。

1.3 3. Muon 优化器与 QK Clip: 稳定训练的秘密武器

提升 token 效率的路径不止于数据质量，优化器本身的革新同样带来了意外之喜。传统上，Adam 优化器是大模型训练的标配，但其内置的动量累积和二阶矩估计带来了较高的计算开销。

而 Muon 优化器，作为一种二阶优化器，以更优雅的方式逼近 Hessian 矩阵，实现了令人瞩目的提升。



解决方案来自一个精巧的技巧：**QK Clip**。该方法在每次前向计算后，对 QK 点积的结果进行动态缩放，将其限定在一个合理的范围内。这样既保留了 Muon 优化器带来的加速优势，又消除了不稳定因素，得到了平稳下降的 loss 曲线。

风险提示


在使用二阶优化器时，必须警惕数值爆炸现象。QK Clip 并非万能，需要针对具体模型规模调整 clip 阈值。过强的 clip 可能抑制模型表达能力，过弱则无法解决问题。建议在训练初期进行小规模消融实验。

核心重点

结论：Muon 优化器配合 QK clip 技术，可以在大规模模型上实现稳定且高效的训练。这为 token efficiency 的提升提供了一条工程上可行的路径。


1.4 4. Kimi Linear 架构与 Delta Attention：下一代基础模型的雏形

如果说 Muon 优化器是对现有架构的“优化”，那么 Kimi Linear 则是架构层面的“颠覆”。当上下文长度达到百万级别时，传统 Transformer 的全注意力机制计算成本完全无法接受。线性注意力（linear attention）应运而生，但此前诸多方案（如 Linear Transformer、Performer）在性能上总是打折扣。



传统线性注意力通过核函数近似将注意力计算降低到线性复杂度，但代价是丢失了对“记忆流”的精细控制。Delta Attention 引入了一个可学习的对角线矩阵 α ，用于动态衰减或增强不同时间步的状态贡献。这相当于为模型增加了一个“记忆阀门”，可以更灵活地选择记住哪些历史信息、遗忘哪些噪声。

实验数据显示，在百万上下文规模下，Kimi Linear 架构的速度是标准注意力的 **6-10 倍**，同时在 Benchmark 上，短程任务不降反升，长程任务更是显著超越基线。这对于需要处理超长序列的 Agent 场景（例如连续数小时的对话、整个代码仓库的推理）是质的飞跃。




核心重点


结论：Kimi Linear 架构（包含 Delta Attention）在保持高效的同时实现了更好的长上下文性能。它被确定为下一代模型 K3 的基础架构。

1.5 5. 超越基准：Agent 能力与模型审美

模型架构和优化策略最终要服务于真实世界的复杂任务。K2 模型及其 thinking 版本已经在核心 Benchmark HLE（Hard Language Evaluation）上超过了 OpenAI 的对应模型，准确率达到 45%。这不仅仅是一个数字，它意味着模型开始具备真正的工具使用能力：可以连续执行两三百步的工具调用，自主完成从信息获取到决策验证的完整流程。



但令人深思的是，在技术讨论的末尾，发言者提出了一个超越技术本身的话题：**模型审美**。“模型开发本质是创造世界观，需要 taste 和审美”，智能是非同质化的，Agent 空间会放大这一特性。这意味着，未来的模型竞争不仅是能力指标的竞赛，更是对价值观、世界观和交互风格的取舍。



风险提示

Agent 能力越强，失控风险越大。连续数百步的工具调用意味着模型可能自主执行有潜在危害的操作（如购买商品、发送信息、修改文件）。必须建立完善的沙箱、审计和熔断机制。

1.6 6. 下一步演进与计划：从 K2 到 K3 的路线图

综合以上技术讨论，会议形成了清晰的决策链：

1. 采用 Muon 优化器配合 QK clip 技术，作为 K3 模型训练的标准配置，以提升 token 效率。
2. 将 Kimi Linear 架构（包含 Delta Attention）作为 K3 的基础架构，突破长上下文瓶颈。
3. 继续 scale 模型，但注重“审美”与“安全”：在增加参数的同时，通过数据筛选、对抗训练和价值观对齐，确保模型行为符合人类预期。
4. 加强开源社区合作，推动更多开发者参与模型、架构和 Agent 应用的创新，形成健康的生态。

1.6.1 近期关键任务

- 在 K2 的基础上进一步 scaling，训练 K3 模型：预计参数规模将提升一个数量级。
- 优化 Kimi Linear 架构的工程实现：特别是底层 CUDA kernel 的编写和显存管理，使得百万级上下文的实时推理成为可能。
- 持续探索 agent 能力：开发更复杂的评测基准，涵盖多步推理、工具组合、错误恢复等场景。
- 加强对模型安全和风险的控制：引入可解释性工具、行为监控器和红队测试。

知识补充

Token efficiency 与 Long context 是预训练的两个核心维度，但不可孤立追求。高 token 效率的数据配比可能会牺牲多样性，从而影响模型在开放域任务上的泛化能力；而过长的上下文如果没有好的记忆控制，反而会引入噪声。Kimi Linear 的 Delta Attention 正是为了解决这一矛盾而生。

从 Scaling Law 的宏观规律，到 Muon 优化器的微观调和，再到 Kimi Linear 的架构变革，这场技术分享清晰地勾勒出一条通往下一代大模型的路径。这条路既是工程优化的必然结果，也

是美学与伦理的选择。当模型能够理解百万 token 的上下文并自主完成数百步任务时，AGI 的曙光或许就不再遥远——只要我们在每一次迭代中，都保持对智能本质的敬畏与好奇。